

Explorando o HuggingFace

Desafio de Comparação de Modelos LLM

Análise de Performance vs. Coerência na Geração de Texto

| Metodologia e Solução

- </> Biblioteca Transformers:** Uso do pipeline 'text-generation' para execução direta.
- 🔧 Infraestrutura:** Execução via Google Colab para processamento em GPU.
- ✎ Benchmarking:** Comparação entre o GPT-2 padrão e a versão destilada (DistilGPT2).



HUGGING FACE

| Resultados da Comparação

GPT-2 (Base)

- **124 Milhões** de parâmetros.
- Respostas mais profundas e coerentes.
- Citou figuras como Stephen Hawking, mantendo o contexto histórico.

DistilGPT2

- **82 Milhões** de parâmetros (33% menor).
- **2x mais rápido** na inferência.
- Apresentou maior repetição de frases e menor variação léxica.

Conclusão: O DistilGPT2 é ideal para aplicações com recursos limitados, enquanto o GPT-2 é superior em tarefas que exigem criatividade.

| Image Sources

Thumbnail for <https://assets.stickpng.com/thumbs/6308b83261b3e2a522f01467.png>

www.stickpng.com

Source: www.stickpng.com